

Padronização de nomenclaturas de minutas de atos judiciais

Um estudo jurimétrico de concentração, conformidade documental e determinantes estatísticos

Jorge L. A. Pedroso — Doutorando em Direito pela UFPE · Working paper · julho de 2026

Resumo. Analisou-se um corpus de 23,025 minutas de atos judiciais (2023–2026), nomeadas segundo o esquema *NPU_ASSESSOR_TIPO_TEMA_SUBTEMA_CLASSE*, com dois objetivos: (i) caracterizar a estrutura de concentração do vocabulário de classificação (temas e subtemas) e (ii) medir a conformidade dos registros a um padrão normativo derivado e estimar seus determinantes. Aplicaram-se medidas de concentração (Gini, índice de Hirschman–Herfindahl, curvas de Lorenz), ajuste à lei de Zipf, testes de associação (qui-quadrado com V de Cramér) e regressão logística multivariada. A distribuição dos temas é fortemente concentrada e adere à lei de Zipf (inclinação $\approx -1,13$; $R^2 = 0.947$); a dos subtemas é substancialmente mais dispersa ($R^2 = 0.853$). Apenas 13.8% dos registros estão plenamente conformes. O tipo de ato e a classe processual são preditores estatisticamente robustos da necessidade de recuperação documental (pseudo- R^2 de McFadden = 0.130; AUC = 0.737). As análises são descritivas e associativas, não causais.

Palavras-chave: jurimetria; padronização terminológica; lei de Zipf; concentração; regressão logística; qualidade de dados.

1. Objeto e problema

A gestão de acervos recursais depende de metadados consistentes. No corpus estudado, a classificação de cada minuta em *tema* e *subtema* é feita em texto livre, o que gera proliferação de rótulos e compromete recuperação, agregação e mensuração. Este estudo quantifica a magnitude do problema e os fatores associados à não conformidade, oferecendo base empírica para a política de padronização. Não se avaliam pessoas: a unidade de análise é a minuta e seus atributos de nomenclatura (tipo de ato, classe processual, tema e subtema).

2. Materiais e métodos

2.1 Base e variáveis

O corpus reúne 23,025 registros consolidados de quatro planilhas anuais. As variáveis analisadas são o *tipo de ato* (despacho, interlocutória, terminativa, RVA, voto-vista), a *classe processual*, o *tema* e o *subtema*, além do *ano*. Rótulos de tema e subtema foram normalizados (acentuação, caixa, pontuação, extensão de arquivo) e reduzidos à forma canônica mais frequente de cada grupo, sem fusão semântica automática.

2.2 Técnicas

Concentração: coeficiente de Gini, índice de Hirschman–Herfindahl normalizado (IHH*) e curvas de Lorenz. Forma da distribuição: ajuste da relação log-log posto×frequência (lei de Zipf) por mínimos quadrados, com coeficiente de determinação R^2 . Associação entre categóricas: teste qui-quadrado de independência com tamanho de efeito V de Cramér. Determinantes da não conformidade: regressão logística multivariada, com razões de chance (OR), intervalos de confiança de 95%, pseudo- R^2 de McFadden e área sob a curva ROC (AUC). Processamento em Python (pandas, scipy, statsmodels, scikit-learn).

Advertência metodológica. Com $n = 23,025$, testes de significância detectam efeitos triviais; por isso a leitura privilegia **tamanhos de efeito** (V de Cramér, OR, R^2), não p-valores. Todas as estimativas são **observacionais**: descrevem associação, não causalção.

3. Resultados

3.1 Caracterização da base

Ano	Minutas	%
2023	5.819	25.3%
2024	7.097	30.8%
2025	7.416	32.2%
2026	2.693	11.7%

Tipo de ato	Minutas	%
RVA	7.802	33.9%
DESPACHO	7.668	33.3%
INTERLOCUTÓRIA	5.144	22.3%
TERMINATIVA	2.352	10.2%
VOTO-VISTA	59	0.3%

Tabelas 1–2. Distribuição por ano e por tipo de ato. RVA e despacho concentram a maior parte da produção.

3.2 Concentração das nomenclaturas

Campo	Rótulos distintos	Gini	IHH*	% rótulos p/ 80%	Zipf (incl.)	R^2
TEMA	2300	0.850	0.028	7.0%	-1.129	0.947
SUBTEMA	6819	0.672	0.010	32.5%	-0.697	0.853
CLASSE	12	0.799	0.346	16.7%	-3.603	0.912

Tabela 3. Medidas de concentração. Quanto maior o Gini e menor a % de rótulos necessária para 80% das minutas, mais concentrada a distribuição.




Figura 1. Curvas de Lorenz. O afastamento da diagonal mede a desigualdade de uso dos rótulos; o tema é o campo mais concentrado.




Figura 2. Ajuste à lei de Zipf (log-log). O tema adere quase idealmente (inclinação ≈ -1); o subtema é mais plano, evidência quantitativa de vocabulário mais fragmentado.




Figura 3. Curva de Pareto do tema: 7.0% dos rótulos respondem por 80% das minutas.

3.3 Conformidade ao padrão

Situação	Registros	%
CONFORME	3.187	13.8%
AJUSTE AUTOMÁTICO	10.231	44.4%
RECLASSIFICAÇÃO	6.244	27.1%
REQUER MINUTA	3.363	14.6%

Tabela 4. Triagem de conformidade em quatro filas de ação (prioridade: requer-minuta > reclassificação > ajuste automático).

Defeito detectado	Ocorrências	% do corpus
Classe com extensão .docx/.pdf	16.968	73.7%
Tema/subtema fora do Catálogo	4.118	17.9%
Uso de “TEMAS PROCESSUAIS” como tema	3.064	13.3%
Subtema truncado (~30 caracteres)	2.951	12.8%
Subtema vazado para a coluna Classe	367	1.6%
Classe ausente	61	0.3%
Tipo VISTA/VOTO VISTA	59	0.3%
Subtema ausente	23	0.1%

Tabela 5. Incidência de cada defeito (um registro pode acumular vários).




Figura 4. Conformidade por ano. A queda de conformes a partir de 2024 decorre da inclusão sistemática da extensão de arquivo na classe — mudança de coleta, não de mérito.

3.4 Associação entre atributos e conformidade

Cruzamento	χ^2	gl	p	V de Cramér	Força
Tipo de ato × ação	7112.5	12	0.00e+00	0.321	moderada
Ano × ação	13384.0	9	0.00e+00	0.440	forte
Classe × requer-minuta	2172.1	6	0.00e+00	0.307	moderada
Eixo (proc./mat.) × requer-minuta	2.8	1	9.72e-02	0.011	desprezível

Tabela 6. Testes de associação. Note-se o resultado **negativo** do eixo processual/material ($V \approx 0,01$; p não significativo): a natureza material ou processual não prediz a necessidade de recuperar a minuta.




Figura 5. Força de associação (V de Cramér) por cruzamento.

3.5 Determinantes da recuperação documental (regressão logística)

Modelou-se a probabilidade de um registro exigir recuperação da minuta original em função do tipo de ato, ano, classe processual e eixo. Categorias de referência: RVA, 2023, apelação cível e eixo material. Ajuste global: pseudo- R^2 de McFadden = **0.130**; AUC = **0.737**; $n = 23,025$.

Preditor	OR	IC 95%	p	signif.
----------	----	--------	---	---------

TIPO=DESPACHO	2.91	2.62–3.24	3.9e-86	sim
TIPO=INTERLOCUTÓRIA	1.15	1.01–1.30	3.6e-02	sim
TIPO=TERMINATIVA	0.70	0.58–0.83	5.0e-05	sim
TIPO=VOTO-VISTA	0.20	0.04–0.92	3.9e-02	sim
ANO=2024	1.49	1.34–1.64	1.4e-14	sim
ANO=2025	0.74	0.66–0.83	3.4e-07	sim
ANO=2026	0.68	0.57–0.80	2.2e-06	sim
CLASSE=AGRAVO DE INSTRUMENTO	2.40	2.20–2.63	6.9e-81	sim
CLASSE=EMBARGOS DE DECLARAÇÃO	1.84	1.59–2.14	1.3e-15	sim
CLASSE=AGRAVO INTERNO	2.07	1.62–2.64	5.3e-09	sim
CLASSE=MANDADO DE SEGURANÇA	1.17	0.69–2.00	5.7e-01	—
CLASSE=OUTRAS/AUSENTE	25.94	21.73–30.97	4.1e-284	sim
EIXO=PROCESSUAL	0.88	0.80–0.96	6.7e-03	sim

Tabela 7. Razões de chance. $OR > 1$ aumenta a chance de exigir a minuta; $OR < 1$ reduz.




Figura 6. Forest plot das razões de chance (escala logarítmica; barras = IC 95%).




Figura 7. Curva ROC do modelo (AUC = 0.737).

Leitura crítica. O OR elevado da categoria “classe ausente/outras” é em parte **tautológico**: a ausência de classe já compõe a não conformidade. Os achados substantivos são o excesso de risco dos **despachos** (OR $\approx$ 2,9) e das **classes recursais** — agravo de instrumento, agravo interno e embargos de declaração — frente à apelação cível.

3.6 Padrão proposto para os RVA de embargos de declaração

Entre os 1,950 RVA que julgam embargos, propõe-se subtema de dois eixos (*resultado* · *vício*), com tema fixo “embargos de declaração”, ancorado no art. 1.022 do CPC. A distribuição de resultados:

Resultado	Registros	%
IMPROVIDOS	1136	58.3%
(indefinido)	453	23.2%
PROVIDOS	220	11.3%
PROVIDOS PARCIALMENTE	141	7.2%

Tabela 8. Resultados dos RVA-embargos. O resultado é recuperável em $\sim 77\%$ dos rótulos atuais; o *vício*, porém, só está registrado em 28% — lacuna que o padrão de dois eixos visa suprir prospectivamente.

4. Discussão

Três achados sustentam a política de padronização. Primeiro, a **concentração**: a adesão do tema à lei de Zipf ($R^2 = 0.947$) indica que um núcleo reduzido de rótulos governa a maioria dos casos — logo, padronizar o topo da distribuição rende cobertura desproporcional. Segundo, o **contraste tema × subtema**: o subtema é quantitativamente mais disperso (Gini 0.67 contra 0.85; inclinação de Zipf mais plana), o que identifica o subtema como o campo que mais exige disciplina. Terceiro, os **determinantes**: a não conformidade não é aleatória — concentra-se em despachos e em classes recursais específicas, o que permite dirigir o esforço de correção.

5. Limitações

(i) As estimativas são observacionais; nenhuma relação causal é afirmada. (ii) A classificação de conformidade é determinística sobre os campos, de modo que a fila de reclassificação pode conter registros legítimos de tema material. (iii) O ajuste de Zipf é descritivo da forma da distribuição, não um teste formal de lei de potência. (iv) O modelo logístico apresenta pseudo- R^2 moderado (0.130): captura parte, não a totalidade, da variação — coerente com o caráter multifatorial da qualidade do dado.

6. Conclusão

O corpus exhibe vocabulário fortemente concentrado, porém heterogêneo em qualidade: apenas 13.8% dos registros estão plenamente padronizados. A estrutura de concentração torna a padronização eficiente (poucos rótulos, muita cobertura), e os determinantes identificados permitem priorizar a correção. A adoção de vocabulário controlado com validação na origem — e, no caso dos embargos, o registro obrigatório do vício do art. 1.022 — é a via para elevar a conformidade de forma sustentável.

Referências

- BRASIL. **Lei n.º 13.105, de 16 de março de 2015** (Código de Processo Civil). Brasília, 2015.
- CRAMÉR, H. **Mathematical Methods of Statistics**. Princeton: Princeton University Press, 1946.
- GINI, C. **Variabilità e mutabilità**. Bologna: Tipografia di Paolo Cuppini, 1912.
- HIRSCHMAN, A. O. The paternity of an index. **The American Economic Review**, v. 54, n. 5, 1964.
- McFADDEN, D. Conditional logit analysis of qualitative choice behavior. In: ZAREMBKA, P. (ed.). **Frontiers in Econometrics**. New York: Academic Press, 1974.
- ZIPE, G. K. **Human Behavior and the Principle of Least Effort**. Cambridge: Addison-Wesley, 1949.

Working paper de circulação restrita. Todos os números derivam do corpus analisado (23,025 registros); dispositivos do CPC conferidos na fonte oficial. Elaborado por Jorge L. A. Pedroso — Doutorando em Direito pela UFPE.